CHECKPOINT B — Reporte Integral de Fases 2, 3 y 4

Auditoría Técnica, Corrección Metodológica y Derivación de Perfiles Electorales

Reto 1: Perfiles Ciudadanos de Participación · Equipo **Byte me** · INE / ENCÍVICA 2024–2026

1. Verificación de Determinismo y Reproducibilidad Estricta

En cumplimiento de los requerimientos de auditoría y la regla de determinismo, el pipeline completo (ingesta de datos brutos desde archivos censales con codificación determinista utf-8-sig en 2024, ordenamiento estricto ORDER BY edocve, seccion, cálculo de tasas mediante la fórmula institucional SV / (SV + NV), filtrado sin imputación, winsorización p1–p99, escalado robusto y partición K-Means++) fue ejecutado dos veces completas desde cero. Se verificaron hashes SHA-256 idénticos bit a bit:

Artefacto / Archivo Generado	Hash SHA-256 (Corrida 1)	Hash SHA-256 (Corrida 2)	Validación
outputs/fase2/etiquetas_finales.parquet	3858e9bde39dfeb9c3e05444c0d75106406f32e1abc359fd31af2397c0b9e911	3858e9bde39dfeb9c3e05444c0d75106406f32e1abc359fd31af2397c0b9e911	**100% Idéntico**
outputs/fase3/perfiles.csv	8a96df7aff28518431c0694c454454f385445e49f1588b2a65fbfa82f6d54442	8a96df7aff28518431c0694c454454f385445e49f1588b2a65fbfa82f6d54442	**100% Idéntico**
outputs/metricas_finales.json	868b975d331c9706ea3c91a7cacbe724df0fdecc9329209d28f3979b17fe2c8c	868b975d331c9706ea3c91a7cacbe724df0fdecc9329209d28f3979b17fe2c8c	**100% Idéntico**

2. Reconciliación de Universos y Cobertura Seccional (Opción B: Cero Imputación)

Explicación de discrepancia entre 72,681 y 70,751: En el corte electoral de 2024 existen **70,751 secciones activas**, compuestas por 62,048 secciones continuas presentes en las 6 elecciones y 8,703 secciones creadas con posterioridad a 2009. Las **72,681 secciones** corresponden a la unión histórica total, que añade 1,930 secciones dadas de baja o fusionadas por reseccionamiento antes de 2024. Para garantizar un análisis libre de sesgo sin recurrir a imputaciones sintéticas, se seleccionó el **Panel Principal (Opción B)** con **53,644 secciones** que representan el **75.82% de las secciones** y el **79.53% de la Lista Nominal de 2024**, cubriendo 2,393 municipios del país.

Etapa de Filtrado	Secciones	Excluidas	% Secciones 2024	Lista Nominal 2024	% LN 2024	Municipios
0. Unión histórica (2009–2024)	72,681	—	102.73%	98,330,348	100.00%	2,477
1. Secciones activas en 2024	70,751	1,930 (bajas pre-2024)	100.00%	98,330,348	100.00%	2,475
2. Panel continuo (2009–2024)	62,048	8,703 (post-2009)	87.70%	85,938,493	87.40%	2,473
3. Captura válida (SV+NV >= 50 en las 6)	54,804	7,244 (sin captura o <50)	77.46%	79,679,192	81.03%	2,402
4. Sin salto consecutivo LN (<0.5x o >2.5x)	53,645	1,159 (de 1,311 en panel)	75.82%	78,199,601	79.53%	2,393
5. Panel Principal Opción B (Cero Imputación)	**53,644**	1 (sin electores 60+)	**75.82%**	**78,199,518**	**79.53%**	**2,393**

3. Serie Nacional 2009–2024 y Validación de Fórmula Oficial SV / (SV + NV)

En los microdatos censales (CCPC), la Lista Nominal se compone de: LN = SV + NV + NS, donde NS corresponde a cuadernillos no disponibles, en recuento o no capturados. Al dividir SV / LN (criterio original erróneo), las secciones sin captura se computaban como 0.0% de participación, deprimiendo artificialmente los promedios en 2018 y 2024 y creando el artefacto del cluster C4. Con la fórmula oficial SV / (SV + NV) ponderada, se reproduce con exactitud el dato censal publicado por el INE en todas las elecciones presidenciales:

Año	Elección	Secciones CCPC	SV+NV=0	NS (% LN)	Erróneo SV/LN (Pond)	Oficial SV/(SV+NV) Pond	Oficial INE Reportado	Panel B (53,644) Pond
2009	Intermedia	64,869	1,733	2.41%	43.39%	**44.46%**	44.6%–44.8%	44.52%
2012	Presidencial	66,805	258	0.22%	61.94%	**62.08%**	**62.1%**	62.72%
2015	Intermedia	68,269	4,051	6.13%	43.77%	**46.63%**	47.7%*	47.41%
2018	Presidencial	67,832	2,517	6.83%	58.11%	**62.37%**	**62.4%**	63.61%
2021	Intermedia	68,708	2,711	4.32%	49.68%	**51.92%**	52.6%*	53.30%
2024	Presidencial	70,751	2,100	6.43%	55.83%	**59.67%**	**59.7%**	61.07%

**Nota: En elecciones intermedias (2015 y 2021), la cifra reportada por los cómputos distritales incorpora casillas especiales, mismas que por diseño censal no se incluyen en las tablas por sección electoral del CCPC.*

4. Resultados de las Pruebas de Robustez del Modelo (Fase 2)

4.1 Transformación de Estabilidad Seccional

Se evaluaron tres formulaciones alternativas en el Panel Principal: (a) 1/CV sin acotar, (b) CV directo winsorizado p1–p99, y (c) log1p(1/CV) winsorizado p1–p99. La formulación original (a) presentaba una curtosis patológica de 31.25 (máx 113.93). La versión (c) fue seleccionada formalmente al reducir la asimetría a 0.99 y la curtosis a 0.57, manteniendo el sentido positivo de estabilidad y superando a (b) en Silhouette (0.1625 vs 0.1611), Davies-Bouldin (1.6109 vs 1.6609) y Calinski-Harabasz (12,676.61 vs 12,299.10).

4.2 Multicolinealidad (VIF) y Ventana Temporal

Control VIF: Las 7 variables seleccionadas registraron factores de inflación de la varianza estrictamente controlados (< 4.0): ratio_participacion_joven = 3.99, brecha_generacional = 3.97, estabilidad_participacion = 3.86, brecha_presidencial_intermedia = 2.98, tendencia_participacion_beta = 2.12, participacion_media_historica = 1.92 y brecha_genero = 1.21. Eliminar ratio_participacion_joven (ARI = 0.4976) o brecha_generacional (ARI = 0.5381) desfigura la partición, pues la primera captura el rezago relativo de la juventud y la segunda la polarización etaria absoluta.
Ventana temporal: Promediar los 6 comicios en las variables demográficas amortigua oscilaciones coyunturales, registrando correlaciones de 0.73 a 0.81 frente al corte único de 2024, pero evitando agrupar por anomalías de una sola jornada (ARI = 0.3579).

4.3 Análisis de Sensibilidad: Universo Opción A frente al Panel Principal B

Para validar que la exclusión de secciones con captura incompleta no sesga los perfiles, se corrió un modelo de sensibilidad (Opción A) sobre el universo continuo de 62,048 secciones (tratando años con captura insuficiente como NaN sin imputar y exigiendo al menos 2 comicios presidenciales y 2 intermedias válidas: N = 61,739). El **ARI en las 53,644 secciones comunes fue de 0.9292**, con una **coincidencia exacta del 97.20%** tras alinear centroides, demostrando que la topología de perfiles es estructuralmente invariante.

4.4 Benchmark de Algoritmos (k=3 a 7, GMM y HDBSCAN)

Algoritmo	Configuración	Inercia	Silhouette	Davies-Bouldin	Calinski-Harabasz	BIC	ARI Bootstrap (100 réplicas al 80%)	Tamaño Mín–Máx (%)
K-Means++	k=3	139,446.3	0.2099	1.4875	16,402.4	—	0.9734 ± 0.0235 [0.9174, 0.9963]	23.5% – 42.6%
K-Means++	k=4	124,339.9	0.1789	1.5380	14,435.4	—	0.9572 ± 0.0253 [0.9091, 0.9915]	16.5% – 32.8%
K-Means++	**k=5 (Seleccionado)**	**115,520.9**	**0.1625**	**1.6109**	**12,676.6**	—	**0.9327 ± 0.0330 [0.8728, 0.9854]**	**12.9% – 30.3%**
K-Means++	k=6	108,211.6	0.1639	1.5709	11,550.7	—	0.9675 ± 0.0162 [0.9375, 0.9887]	11.0% – 28.3%
K-Means++	k=7	102,430.2	0.1539	1.5736	10,673.2	—	0.9496 ± 0.0798 [0.5652, 0.9837]	10.0% – 22.6%
GMM (full)	k=5	—	0.0326	3.7745	5,030.3	561,305.4	—	15.0% – 22.7%
HDBSCAN	min_samples=10	—	0.4140*	0.6564*	620.2*	—	50.73% clasificado como ruido	2 clusters

4.5 Matriz de Transición: Desaparición del Artefacto C4 Original

El ARI global entre las etiquetas viejas y las nuevas es de tan solo **0.3986**. El **48.85% de las secciones del antiguo C4** (4,114 secciones) fueron correctamente excluidas del panel por carecer de cuadernillos capturados (SV+NV < 50), y las restantes se redistribuyeron en los verdaderos perfiles cívicos. Esto confirma de manera empírica e irrefutable que el C4 original era un artefacto del error de ingesta.

5. Caracterización de los 5 Nuevos Perfiles Ciudadanos de Participación

Conforme a la **Regla 3.2**, los nombres fueron derivados estrictamente a partir de las 2 o 3 variables con mayor desviación estándar ($|z| \geq 0.5$) respecto a la media nacional del Panel Principal (N = 53,644 secciones; 78.2 millones de electores en LN 2024):

Código y Nombre Propuesto (Regla 3.2)	Secciones (% Panel)	Lista Nominal 2024 (% Panel)	Variables Rectoras ($\|z\| \geq 0.5$)	Part. Media Histórica	Brecha Pres.–Inter.	Brecha Género	Ratio Joven (Medias)	Tipo Sección (U / R / M)
C0: Abstencionismo Crónico con Rezago Juvenil	9,535 (17.77%)	14,988,837 (19.17%)	Ratio Joven (z = -1.19) Brecha Generacional (z = +0.87) Part. Media (z = -0.84)	**48.55%** (z = -0.84)	+12.41 pts (z = -0.09)	+6.87 pts (z = -0.22)	**0.7578** (z = -1.19)	62.6% U 27.3% R 10.2% M
C1: Participación Intermitente de Ciclo Presidencial	16,244 (30.28%)	25,605,748 (32.74%)	Brecha Pres.–Inter. (z = +0.90) Estabilidad (z = -0.72) Tendencia Beta (z = +0.63)	53.83% (z = -0.27)	**+19.42 pts** (z = +0.90)	+7.27 pts (z = -0.12)	0.8289 (z = -0.14)	**83.2% U** 9.6% R 7.2% M
C2: Alta Participación Consolidada y Estable	6,947 (12.95%)	9,024,489 (11.54%)	Estabilidad (z = +1.64) Brecha Pres.–Inter. (z = -1.20) Brecha Gen. (z = -1.11) Part. Media (z = +1.06)	**66.08%** (z = +1.06)	**+4.67 pts** (z = -1.20)	+7.48 pts (z = -0.07)	**0.9105** (z = +1.06)	45.8% U 40.4% R 13.9% M
C3: Constancia de Ciclo con Liderazgo Femenino y Estancamiento Secular	10,689 (19.93%)	16,809,225 (21.50%)	Brecha Género (z = +0.97) Tendencia Beta (z = -0.79) Brecha Pres.–Inter. (z = -0.73) Estabilidad (z = +0.65)	57.14% (z = +0.09)	+7.96 pts (z = -0.73)	**+11.96 pts** (z = +0.97)	0.8216 (z = -0.25)	48.5% U **41.8% R** 9.8% M
C4: Participación en Ascenso con Juventud Activa	10,229 (19.07%)	11,771,219 (15.05%)	Brecha Generacional (z = -0.95) Ratio Joven (z = +0.87) Tendencia Beta (z = +0.72) Brecha Género (z = -0.57)	59.94% (z = +0.40)	+14.66 pts (z = +0.23)	**+5.35 pts** (z = -0.57)	**0.8979** (z = +0.87)	61.6% U 29.3% R 9.2% M
Media Nacional Panel B	**53,644 (100%)**	**78,199,518 (100%)**	—	**56.30%**	**+13.07 pts**	**+7.79 pts**	**0.8385**	**66.4% U / 23.9% R / 9.7% M**

6. Estrategias Focalizadas y Viabilidad Operativa Institucional (Fase 4)

Cada estrategia se diseñó respetando estrictamente el marco de atribuciones del INE, el mandato de la ENCÍVICA 2024–2026, con narrativas neutrales sin adjetivaciones denostativas y asignación precisa de unidades operativas:

Perfil	Factor Causal (Hipótesis)	Acción Operativa y Canales INE	Unidad Responsable	Costo Estimado	Meta Cuantitativa	Lema Neutral
C0: Abstencionismo Crónico Joven	Hipótesis: Barreras al primer voto, movilidad estudiantil/laboral y menor socialización cívica.	Brigadas universitarias de actualización de credencial en IES y difusión focalizada de 'Ubica tu Casilla'.	DECEyEC, Juntas Distritales y DERFE	Bajo-Medio (~$18-28M MXN)	+3.0 a +4.5 pts en tasa 18-29 en >=60% de secciones.	*'Tu primer voto abre camino: infórmate, ubica tu casilla y participa'*
C1: Intermitente Presidencial	Hipótesis: Desconocimiento de atribuciones legislativas en comicios intermedios urbanos.	Campaña en transporte metropolitano masivo, foros distritales y difusión QR del sistema 'Conóceles'.	DECEyEC y Juntas Locales / Distritales	Medio (~$25-40M MXN)	Reducir brecha pres.-inter. en 3.5 a 5.0 pts en 2027.	*'La democracia se ejerce cada tres años: conocer las atribuciones legislativas importa'*
C2: Alta Consolidada y Estable	Hipótesis: Sólida cohesión comunitaria; riesgo de fatiga en integración de casillas.	Sistematización de buenas prácticas cívicas, talleres juveniles de relevo y reclutamiento temprano de MDC.	DECEyEC y DECE (Juntas Distritales)	Bajo (~$8-14M MXN)	Mantener part. >65% y 100% de casillas con propietarios.	*'Participar fortalece a tu comunidad: formemos a las próximas generaciones de funcionariado'*
C3: Liderazgo Femenino Rural	Hipótesis: Migración laboral masculina y envejecimiento en localidades rurales dispersas.	Brigadas móviles en zonas rurales, difusión en radios comunitarias/indígenas y revisión de accesibilidad de casillas.	Juntas Distritales, DECEyEC y DEOE	Medio (~$20-32M MXN)	Incrementar en +2.5 pts part. masculina (51% a 53.5%).	*'Cada voz en la comunidad cuenta: facilitemos el acceso a la casilla para todas las edades'*
C4: En Ascenso con Juventud	Hipótesis: Dinamismo demográfico e integración juvenil que requiere consolidarse como hábito.	Foros juveniles 'Diálogos por la Democracia', alianzas con colectivos estudiantiles y verificación informativa.	DECEyEC y Juntas Distritales	Bajo-Medio (~$12-20M MXN)	Sostener part. >60% en comicios intermedios de 2027.	*'Tu participación transforma tu entorno: mantengamos activa la conversación cívica'*